

**Ad Soyad:** Amr Nawaf Saeed Walidi

**No:** 02210224064

## **Gemi Algılama Konusundaki Üç Makalenin Kapsamlı Özeti**

### **GİRİŞ**


Gemi tespiti, deniz güvenliği, çevresel izleme, gemi trafiği yönetimi ve askeri operasyonlarda geniş kapsamlı uygulamalara sahip kritik bir araştırma alanıdır. Geleneksel manuel gemi tespit yöntemleri zaman alıcı, hataya açık ve maliyetlidir ve bu da bilgisayarlı görüş ve makine öğrenimi tekniklerini doğruluk ve verimliliği artırmak için olmazsa olmaz hale getirir. Derin öğrenme modellerinin Sentetik Açıklıklı Radar (SAR) ve optik uydu görüntüleri gibi uzaktan algılama teknolojileriyle bütünleştirilmesi, gemi tespit yeteneklerini önemli ölçüde iyileştirerek çeşitli deniz ortamlarında gerçek zamanlı, büyük ölçekli izleme olanağı sağlamıştır.

Bu çalışmalarda gemi tespiti için üç derin öğrenme tabanlı nesne tespit modeli uygulanmıştır: Hızlı R-CNN, Maske R-CNN ve YOLOv8/YOLOv9. Her yaklaşım, mevcut metodolojilerin güçlü ve zayıf yönlerini sergileyen farklı görüntü edinme teknikleri ve sinir ağı mimarileri kullanır.

### **1. FASTER R-CNN VE SENTINEL-1 SAR VERİLERİNİ KULLANARAK GEMİ TESPİTİ**

İlk çalışma, iki aşamalı derin öğrenme çerçevesi olan Daha Hızlı R-CNN'i Sentinel-1 SAR verileriyle birlikte kullanarak gemi tespitini araştırıyor. SAR görüntüleri yüksek çözünürlüklü, hava koşullarından bağımsız görüntüleme sağlıyor ve bu da onları gece veya sisli hava gibi düşük görüş koşullarında çalışabildikleri için deniz izleme için oldukça uygun hale getiriyor. Bu avantaj, SAR tabanlı tespiti, uygun ışık koşullarına bağlı olan optik görüntülemeye değerli bir alternatif haline getiriyor.

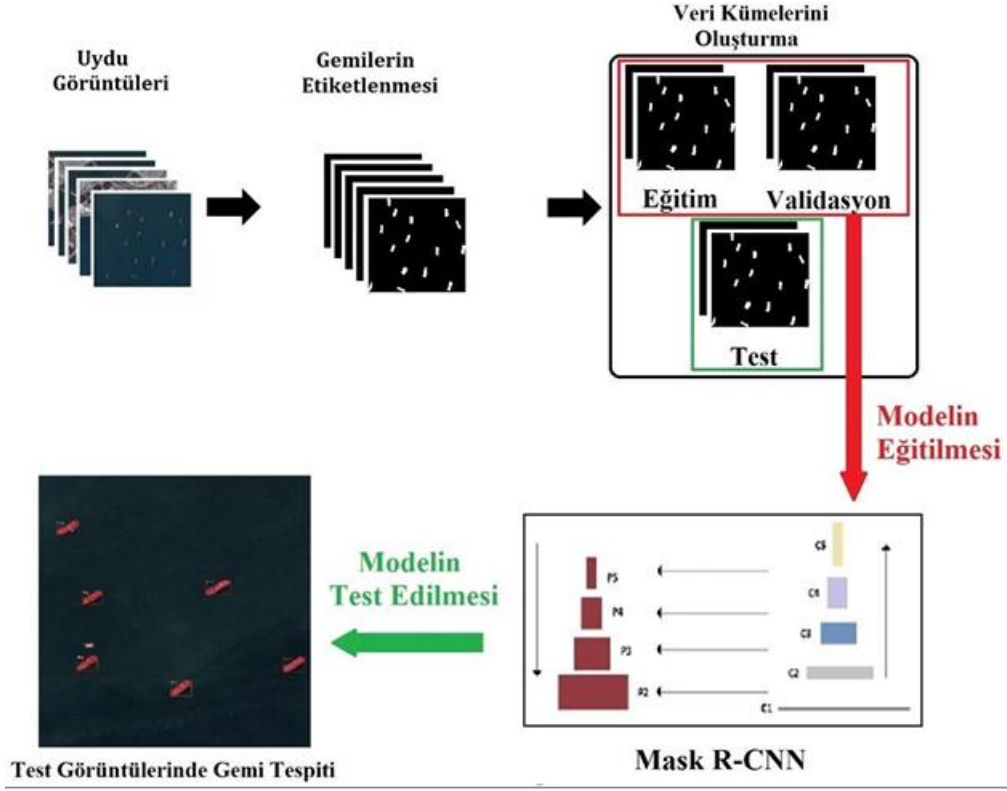
Araştırmacılar, Faster R-CNN modelini Sentinel-1 verileri üzerinde eğitti ve kargo gemileri, balıkçı tekneleri ve konteyner gemileri dahil olmak üzere çeşitli gemi tiplerini tespit etmede %86,11'lik bir doğruluk elde etti. Model, düşük bir yanlış pozitif oranı gösterdi, yani görüntülerdeki gemileri diğer nesnelerden başarıyla ayırt etti.



**Şekil 1:** Önerilen gemi tespit algoritması kullanılarak Sentinel-1 VH SAR görüntülerinden çıkarılan gemiler (kırmızı ile işaretlendi).

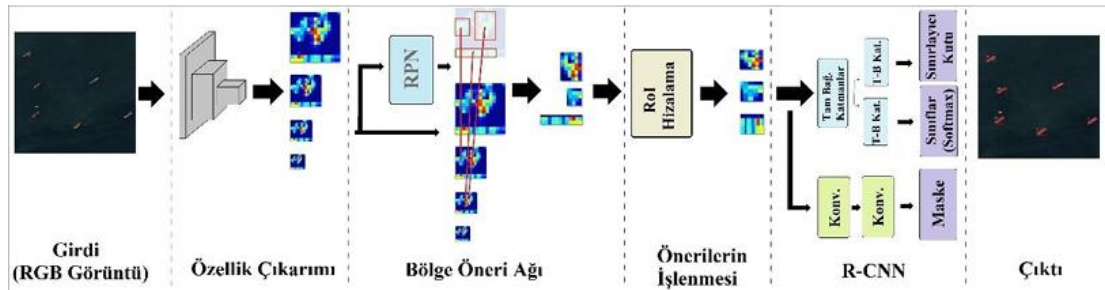
## 2. MASK R-CNN KULLANARAK OPTİK UYDU GÖRÜNTÜLERİNDE GEMİ ALGILAMA

Bu çalışma, bölge tabanlı bir evrişimli sinir ağı (CNN) modeli olan Mask R-CNN kullanarak optik uydu görüntülerinde gemileri algılamaya odaklanmaktadır. Sadece sınırlayıcı kutular üreten Faster R-CNN'den farklı olarak, Mask R-CNN algılanan nesneleri ana hatlarıyla belirten hassas segmentasyon maskeleri üreterek bir adım daha ileri gider. Bu yetenek, özellikle yoğun nüfuslu deniz alanlarında daha ayrıntılı gemi tanımlamasına olanak tanır.



**Şekil 2:** Çalışmadaki Gemi Tespit Prosedürü


Araştırmacılar, 1.838 yüksek çözünürlüklü uydu görüntüsünden (1 metrelik mekansal çözünürlük) oluşan bir veri kümesi oluşturdular ve GIS yazılımı kullanarak 3.279 gemiyi manuel olarak etiketlediler. Daha sonra Mask R-CNN modeli bu veri kümesi üzerinde eğitildi ve test edildi. Çalışma, Mask R-CNN'nin zorlu deniz ortamlarında bile gemileri etkili bir şekilde algıladığını, ancak gemiler birbirine yakın kümelendiğinde zorluk çektiğini buldu.



**Şekil 3:** Çalışmadaki Gemi Tespit Prosedürü

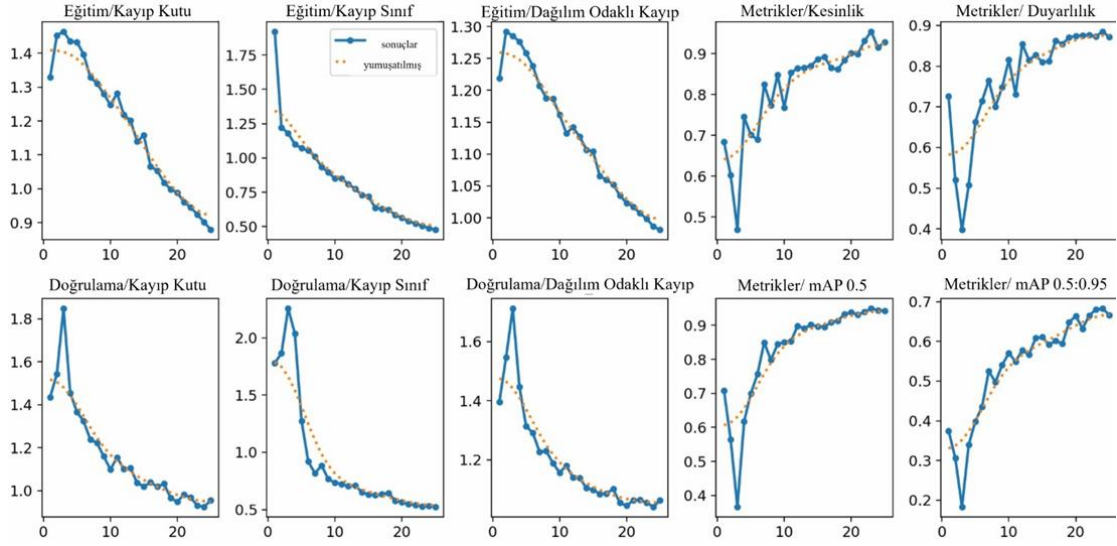
### 3. YOLO TABANLI GEMİ ALGILAMA: YOLOV8 VE YOLOV9'U DEĞERLENDİRME

Son çalışma, tek aşamalı bir nesne algılama modeli olan YOLO (You Only Look Once) mimarisini kullanarak gerçek zamanlı gemi algılamayı araştırıyor. Bölge teklif ağlarına (RPN'ler) ve birden fazla işleme aşamasına dayanan Faster R-CNN ve Mask R-CNN'in aksine, YOLO algılama ve sınıflandırmayı tek bir ağda gerçekleştirerek hızı ve verimliliği önemli ölçüde iyileştiriyor. Bu çalışma, Google Earth uydu görüntülerinde gemi algılama için YOLOv8 ve YOLOv9'u karşılaştırarak doğruluklarını ve performanslarını değerlendiriyor.

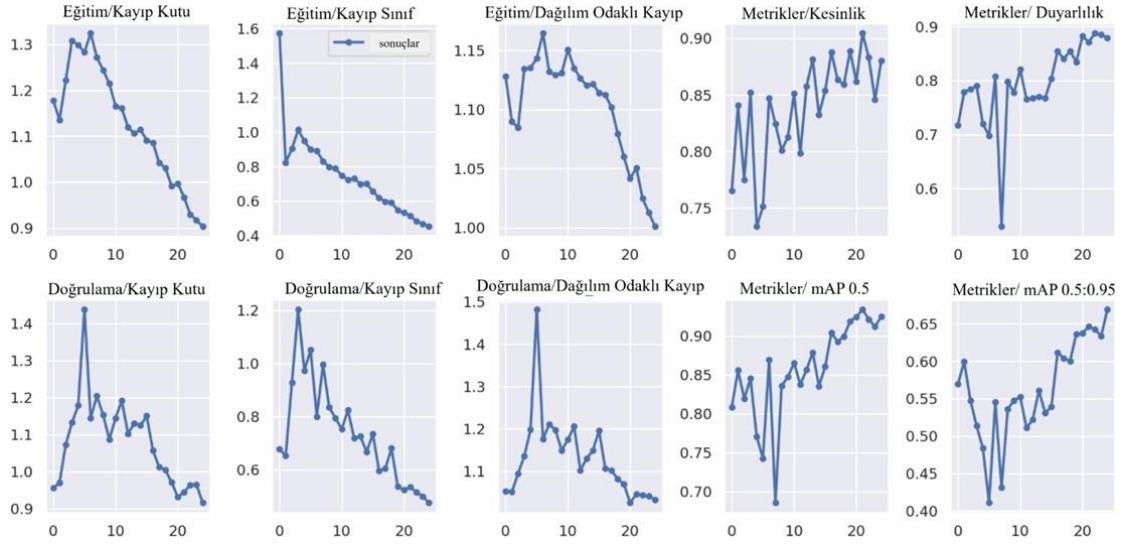


**Şekil 4:** YOLO Mimarisinin Bölümleri (Parts of YOLO Architecture)

1.658 uydu görüntüsünden oluşan bir veri kümesi derlendi ve eğitim (%86), doğrulama (%10) ve test (%5) kümelerine ayrıldı. Görüntüler, eğitim etkinliğini artırmak için önceden işlendi ve zenginleştirildi. Hem YOLOv8 hem de YOLOv9 modelleri, 16'lık bir parti büyüklüğü ile 25 yineleme için eğitildi ve hassasiyet, geri çağırma ve ortalama hassasiyet (mAP) temelinde değerlendirildi.



**Şekil 5:** YOLOv8 Eğitim Metrikleri (YOLOv8 Training Metrics)



**Şekil 6:** YOLOv9 Eğitim Metrikleri (YOLOv9 Training Metrics)

## SONUÇ

Bu üç çalışma, farklı sinir ağı mimarileri ve uydu görüntüleme teknolojilerinden yararlanarak deniz gözetimini geliştirmek için derin öğrenmenin gemi tespitinde artan rolünü göstermektedir. Her yaklaşımın kendine özgü avantajları vardır:

1. Sentinel-1 SAR verileriyle daha hızlı R-CNN, her türlü hava koşulunda oldukça etkilidir ve bu da onu güvenilir, uzun vadeli gemi takibi için ideal hale getirir.

2. Optik uydu görüntüleriyle Mask R-CNN, liman yönetimi ve deniz trafiğı analizi için faydalı olan ayrıntılı segmentasyon sağlar ancak sıkışık gemilerde zorlanır.
3. YOLOv9, doğruluk ve hız açısından YOLOv8'i geride bırakarak gerçek zamanlı gemi tespit yetenekleri sunar ve bu da onu sahil güvenlik ve askeri operasyonlar için umut verici bir araç haline getirir.

## KAYNAKLAR

**İlk çalışma:** <https://dergipark.org.tr/tr/download/article-file/3022765>

**İkinci çalışma:** <https://dergipark.org.tr/tr/download/article-file/3740721>

**Üçüncü çalışma:** <https://dergipark.org.tr/tr/download/article-file/4333485>